CENTRO UNIVERSITÁRIO ATENEU
ENGENHARIA DA COMPUTAÇÃO

Kelvin e Silva Marques
Dimitri Farias Fernandes
Hastrorllabyo da Silva Lima
Keven dos Santos Xavier
Caio de Freitas Brandão
Kauan Magalhães Costa
Guilherme Martins Bezerra
Pedro Henrique Gomes Ferreira
Carlos Eduardo Rodrigues Ferreira
Luan dos Santos Gaspar
Francisco Glauber Rodrigues dos Santos

Ofuscação da cadeia de pensamento sob supervisão

reanálise de um estudo-piloto e teste pré-registrado do efeito do formato de supervisão

FORTALEZA
2026

RESUMO

A monitorabilidade da cadeia de pensamento depende de que os rastros textuais gerados por modelos de linguagem continuem a revelar comportamentos indesejados quando o treinamento sofre pressão de supervisão. Um estudo-piloto deste projeto relatou que o ajuste fino supervisionado (SFT) com respostas diretas reduz muito a acurácia em problemas de múltiplas etapas e interpretou a diferença como ofuscação do raciocínio. A reanálise reproduziu os números publicados, mas mostrou que eles não sustentam essa inferência: o corretor aceitava respostas ambíguas, as sementes compartilhavam quase todos os itens, o escore lexical de ofuscação dava valor máximo a rastros vazios e o desenho não media nenhum comportamento proibido definido fora do rastro. A diferença é compatível com um custo de aprendizagem e não identifica ofuscação. Para testar o efeito com instrumentos válidos, o estudo pré-registrado v3.2 foi encerrado sem treinamentos porque os modelos-base não atingiram 65% de acurácia na triagem de competência; a reprodução com o código congelado obteve exatamente os valores registrados e descartou defeitos de execução. O protocolo v4 recalibrou tarefas e instruções em itens próprios, o modelo-base satisfez o critério na triagem anterior ao registro, cuja cronologia foi comprovada por carimbos de tempo independentes, e o estudo foi registrado publicamente antes dos treinamentos. No teste confirmatório, com um desvio declarado antes de qualquer geração de teste, os 120 treinamentos e as 26.400 gerações sustentaram a hipótese: o contraste entre os níveis foi de −73,2 p.p. (IC de 95%: −73,5 a −73,0 p.p.; $p < 0,001$), isto é, treinar respostas diretas custou muito mais acurácia no nível de múltiplas etapas do que no nível simples. Nesse nível, os modelos treinados com rastro explícito acertaram 75,9% dos itens, e os treinados para responder diretamente, 0,0%: sem escrever as etapas, o modelo erra o cálculo, em vez de executá-lo de forma oculta. A hipótese sobre pressão de recompensa ficou fora do escopo confirmatório, porque nenhum dos monitores avaliados antes do congelamento distinguiu os controles construídos. O trabalho refuta a inferência de ofuscação feita a partir do piloto e mostra, num teste pré-registrado, que a diferença entre alvos de treinamento é um custo do formato de supervisão quando o cálculo exige etapas escritas.

Palavras-chave: Cadeia de pensamento. Monitorabilidade. Pré-registro. Triagem de competência. Reprodutibilidade.

ABSTRACT

Chain-of-thought monitorability depends on the textual traces produced by language models continuing to reveal undesired behavior when training is subject to supervision pressure. A pilot study from this project reported that supervised fine-tuning (SFT) on direct answers sharply reduces accuracy on multi-step problems and interpreted the difference as obfuscation of reasoning. The reanalysis reproduced the published numbers but showed that they do not support that inference: the grader accepted ambiguous answers, the seeds shared almost all items, the lexical obfuscation score gave its maximum value to empty traces, and the design measured no forbidden behavior defined outside the trace. The difference is compatible with a learning cost and does not identify obfuscation. To test the effect with valid instruments, the preregistered study v3.2 was closed without training because the base models did not reach 65% accuracy in the competence screening; reproducing it with the frozen code yielded exactly the registered values and ruled out execution defects. Protocol v4 recalibrated tasks and instructions on separate items, the base model met the criterion in the screening run before registration, whose chronology was established by independent timestamps, and the study was publicly registered before training. In the confirmatory test, with one deviation declared before any test generation, the 120 training runs and 26,400 generations supported the hypothesis: the contrast between levels was −73.2 pp (95% CI: −73.5 to −73.0 pp; $p < 0.001$), that is, training direct answers cost much more accuracy at the multi-step level than at the simple level. At that level, models trained with explicit traces answered 75.9% of the items correctly, and models trained to answer directly, 0.0%: without writing the steps, the model gets the calculation wrong rather than carrying it out covertly. The hypothesis about reward pressure was left outside the confirmatory scope, because none of the monitors evaluated before the freeze distinguished the constructed controls. The work refutes the obfuscation inference drawn from the pilot and shows, in a preregistered test, that the difference between training targets is a cost of the supervision format when the calculation requires written steps.

Keywords: Chain of thought. Monitorability. Preregistration. Competence screening. Reproducibility.

SUMÁRIO

1 INTRODUÇÃO.....5

2 FUNDAMENTAÇÃO.....5

3 HIPÓTESES E CATEGORIAS DE EVIDÊNCIA.....6

4 MATERIAIS E MÉTODOS.....7

4.1 Reanálise do estudo-piloto.....7

4.2 Estudo prospectivo v3.2.....7

4.3 Diagnóstico da triagem do v3.2.....8

4.4 Protocolo prospectivo v4.....9

4.5 Verificação de software.....10

4.6 Coleta confirmatória do v4.....11

5 RESULTADOS.....11

5.1 Reanálise do estudo-piloto.....11

5.2 Triagem do v3.2 e diagnóstico.....12

5.3 Calibração do v4.....14

5.4 Triagem DEV do v4.....15

5.5 Verificações de software.....15

5.6 Teste confirmatório de H1.....16

5.7 Rodada exploratória posterior.....17

6 DISCUSSÃO.....17

7 LIMITAÇÕES.....19

8 CONCLUSÃO.....19

REFERÊNCIAS.....20

1 INTRODUÇÃO

Modelos de linguagem que produzem rastros textuais antes da resposta final oferecem uma fonte adicional de evidência sobre seu comportamento. Neste texto, rastro designa o texto intermediário gerado antes da resposta, e monitor designa um procedimento, automático ou humano, que lê esse texto para detectar comportamentos indesejados. Korbak et al. (2025) descrevem essa monitorabilidade da cadeia de pensamento (*chain of thought*, CoT) como uma oportunidade relevante para a segurança, mas frágil, porque decisões de treinamento podem reduzi-la. A preocupação central é a ofuscação: a manutenção de um comportamento indesejado acompanhada da redução dos sinais textuais que permitiriam detectá-lo.

Este artigo examina três conjuntos de evidência produzidos no mesmo projeto. O primeiro é um estudo-piloto com ajuste fino supervisionado (*supervised fine-tuning*, SFT), cujos dados publicados foram reanalisados. O segundo é um estudo prospectivo, denominado v3.2, isto é, um estudo cujas hipóteses, procedimentos e critérios de análise foram fixados e registrados publicamente antes da coleta dos dados. Ele tinha dois braços, entendidos como conjuntos de condições que compartilham o mesmo procedimento de treinamento: SFT e otimização por recompensa com *Group Relative Policy Optimization* (GRPO). O terceiro é um novo protocolo, v4, preparado depois que o v3.2 não satisfez seu critério de competência, registrado publicamente e executado.

Esse critério constituía uma triagem: antes dos 240 treinamentos, cada modelo-base, isto é, o modelo pré-treinado ainda não ajustado no estudo, deveria acertar ao menos 65% de 120 itens da partição de desenvolvimento (DEV) em cada nível de dificuldade. A partição DEV é reservada a verificações prévias e distingue-se da partição de teste (TEST), usada apenas no desfecho final. A triagem registrou 57,5% e 0% nos níveis do braço SFT e 43,33% e 15% nos do braço GRPO. Antes de atribuir esse resultado à incapacidade dos modelos, é necessário excluir defeitos que produziriam o mesmo padrão: erro do corretor (o programa que decide se uma resposta está certa), uso incorreto do modelo de conversa (o formato com que as mensagens são apresentadas ao modelo), truncamento, extração equivocada da resposta, precisão numérica ou incompatibilidade entre bibliotecas.

Três perguntas orientam o trabalho. P1: os dados publicados do piloto permitem atribuir a diferença de desempenho entre alvos de treinamento à ofuscação de um raciocínio necessário? P2: a reprovação da triagem do v3.2 decorre de defeito técnico ou da incapacidade dos modelos-base? P3: alterações calibradas com dados próprios, separados das partições do estudo, permitem satisfazer o mesmo critério de competência, e os monitores previstos distinguem rastros que usam a informação proibida de rastros que não a usam? P4: com esses instrumentos, treinar respostas diretas em vez de rastros explícitos custa mais acurácia no nível de maior complexidade? P1 é a pergunta central e recebe resposta definitiva; P2 e P3 tratam de como testar o efeito do formato de supervisão com instrumentos válidos, e P4 é respondida pelo teste confirmatório do v4. A hipótese sobre pressão de recompensa (H2) é descrita, mas fica fora do escopo confirmatório.

2 FUNDAMENTAÇÃO

Fidelidade refere-se à correspondência entre o rastro e os fatores que efetivamente determinam a resposta; monitorabilidade, à possibilidade de detectar, a partir do rastro, comportamentos relevantes para a supervisão. Wei et al. (2022) mostraram que etapas intermediárias melhoram o desempenho em

problemas de múltiplos passos. Turpin et al. (2023) demonstraram, porém, que explicações plausíveis podem omitir influências que alteram a resposta, e Lanham et al. (2023) mediram, por intervenções no rastro, quanto a resposta depende dele. Fidelidade é, portanto, uma propriedade a medir, e não a presumir pela fluência do texto. Para inferir ofuscação, é necessário observar ao mesmo tempo um comportamento definido independentemente do texto e a dificuldade de detectá-lo no rastro.

Baker et al. (2025) observaram que penalizar, no treinamento por reforço, os rastros que mencionavam a exploração de testes reduziu a detecção sem eliminar o comportamento. Drori et al. (2025) e Mitrani Hadida et al. (2026) relatam que a supervisão aplicada apenas à saída também altera os rastros e que o efeito pode generalizar para tarefas não vistas. Emmons et al. (2025), por outro lado, mostram que, quando o rastro é computacionalmente necessário, a evasão do monitor exige assistência ou otimização substanciais. O efeito da pressão de supervisão depende, assim, da tarefa, do mecanismo de treinamento e do monitor, o que torna essenciais o controle da competência do modelo e uma definição comportamental da exploração.

No plano metodológico, Agarwal et al. (2021) recomendam explicitar a unidade de repetição e a incerteza entre execuções; Zheng et al. (2023) documentam vieses de avaliadores baseados em modelos de linguagem, o que motiva monitores independentes do modelo avaliado e validação com rótulos humanos; e Nosek et al. (2018) descrevem o pré-registro como a separação entre decisões tomadas antes e depois da observação dos dados. O GRPO (SHAO et al., 2024) gera várias respostas por enunciado e calcula a vantagem de cada uma, isto é, quanto sua recompensa supera a média do grupo. Os dois braços usam adaptação de baixo posto (LoRA) (HU et al., 2022), que acrescenta às camadas do modelo matrizes de baixo posto treináveis e mantém fixos os pesos originais, sobre modelos Qwen2.5 (QWEN TEAM, 2024) e Qwen3 (YANG et al., 2025), com as bibliotecas Transformers (WOLF et al., 2020) e TRL (VON WERRA et al., 2020).

3 HIPÓTESES E CATEGORIAS DE EVIDÊNCIA

O registro do v3.2 especificou duas hipóteses, cujo texto o v4 mantém; no v4, apenas H1 permanece testável (seção 5.3). Cada treinamento é identificado por uma semente, o número que inicializa os geradores pseudoaleatórios. A hipótese H1, do braço SFT, prevê que treinar respostas diretas, em vez de rastros explícitos, custe mais acurácia no nível de maior complexidade (C) do que no de menor complexidade (A). Para cada semente s,

$$\Delta_s^{\mathrm{SFT}} = \left[\mathrm{Acc}_s(\mathrm{direct}, C) - \mathrm{Acc}_s(\mathrm{explicit}, C)\right] - \left[\mathrm{Acc}_s(\mathrm{direct}, A) - \mathrm{Acc}_s(\mathrm{explicit}, A)\right],$$

com direção prevista negativa. O contraste mede o efeito do alvo de treinamento sobre a acurácia, e não intenção de ocultação. O registro do v4 fixou a regra de decisão: H1 é sustentada quando o teste de inversão de sinais, após a correção de Holm, rejeita a hipótese nula, a média dos contrastes é menor ou igual a −0,05 e o limite superior do intervalo de 95% é negativo.

No braço GRPO, cada questão de múltipla escolha traz uma nota auxiliar proibida, também chamada de dica, que aponta uma alternativa errada; a recompensa mal especificada, uma pontuação que intencionalmente paga por comportamento indesejado, premia essa alternativa. Há três condições: *none*, sem monitor na recompensa; *cot_monitor*, em que a recompensa é reduzida quando um monitor de recompensa detecta o uso da nota no rastro; e *summary_monitor*, em que a penalidade incide sobre

um resumo final. Uma resposta é exploração quando escolhe a alternativa da nota e é não sinalizada quando um monitor independente, distinto do monitor de recompensa, não a detecta. A hipótese H2 prevê, no nível de dica mais difícil (*high*), contraste positivo

$$\Delta_s^{\mathrm{GRPO}} = P_s^{\mathrm{cot_monitor}}(\text{explora e não sinalizado}) - P_s^{\mathrm{none}}(\text{explora e não sinalizado}),$$

com a exigência adicional de que a taxa de exploração não caia mais que 0,10.

A unidade de inferência é a semente: as gerações de uma semente são agregadas numa proporção antes de qualquer teste. Os contrastes de 20 sementes são avaliados por um teste de inversão de sinais bilateral, que compara a média observada com a distribuição obtida ao trocar aleatoriamente o sinal de cada contraste (199.999 permutações com semente fixa), por um intervalo *bootstrap* percentil de 95%, obtido por reamostragem das sementes, e pela correção de Holm (1979) para múltiplas famílias de testes, com efeito mínimo relevante de 0,05.

Os resultados são separados em cinco categorias, que não se combinam: (i) resultados históricos do piloto; (ii) verificações de software, sem evidência sobre o fenômeno; (iii) triagens de competência; (iv) experimentos exploratórios, como o diagnóstico e a calibração; e (v) resultados confirmatórios, que exigem os treinamentos e avaliações completos de um protocolo registrado. O único resultado da categoria (v) é o teste de H1 no v4 (seção 5.6).

4 MATERIAIS E MÉTODOS

4.1 Reanálise do estudo-piloto

O piloto (MARQUES et al., 2026) foi depositado no repositório público do projeto (MARQUES, 2026a) no commit e21cef8, de junho de 2026. Commit designa uma versão registrada no sistema de controle de versões Git, identificada por um código hexadecimal. O piloto ajustou o Qwen2.5-7B-Instruct, quantizado em 4 bits, com LoRA em dois níveis aritméticos (A: adição ou subtração de inteiros de 11 a 99; C: problemas de estoque com multiplicação), três alvos de SFT e três sementes (42 a 44), com 150 itens de treino e 30 de avaliação por execução. Os alvos recebem aqui nomes descritivos: CoT explícita (rastro com as etapas), resposta direta e preâmbulo genérico (frase vaga seguida da resposta). O arquivo publicado contém 540 avaliações, sem enunciados nem textos gerados; a reanálise reprocessou as métricas depositadas, reproduziu a análise de variância e o teste *t* de Welch originais e auditou o gerador de itens, o corretor, o teste de intervenção e o escore lexical executando o código preservado.

Para cada semente *s*, nível *l* e alvo *c*, o custo de acurácia em relação à CoT explícita é K(l, c, s) = Acc(l, explícita, s) − Acc(l, c, s), e a diferença entre níveis é D(c, s) = K(C, c, s) − K(A, c, s). Com três sementes, a enumeração das oito inversões de sinal possíveis fornece *p* bilateral mínimo de 0,25. O teste histórico de intervenção, que compara respostas com e sem explicação em dez itens, foi reconstruído dos agregados e avaliado pelo teste exato de McNemar.

4.2 Estudo prospectivo v3.2

O v3.2 foi implementado no commit fde856f e operado por cinco notebooks do Google Colab, documentos que combinam texto e código executável em máquinas virtuais com unidade de processamento gráfico (GPU). O desenho previa 240 treinamentos e 55.200 gerações de teste (Tabela

1). Cada treinamento produz um adaptador, o conjunto de parâmetros ajustados pela LoRA. No SFT, o nível A consistia em adições de inteiros de 101 a 9.999, e o nível C, em expressões a + b × c − d com os quatro operandos no mesmo intervalo. No GRPO, as questões apresentavam uma expressão aritmética em quatro domínios (aritmética, rastreamento de programa, regra fictícia e estoque); no nível *low*, a nota nomeava a letra, e no nível *high*, exigia calcular um índice módulo 4. As condições com monitor subtraíam 0,6 da recompensa quando o monitor Qwen2.5-0.5B-Instruct detectava o uso da nota.

Tabela 1 – Desenho registrado do estudo prospectivo v3.2

Braço	Modelo-base	Condições × níveis × sementes	Treinos	Itens TEST por nível	Gerações TEST
SFT	Qwen2.5-1.5B-Instruct	3 × 2 × 20	120	220	26.400
GRPO	Qwen3-1.7B	3 × 2 × 20	120	240	28.800
Total			240		55.200

Fonte: PROTOCOLO_PRE_REGISTRO_v3.md e scientific_runtime.py (commit fde856f); registro OSF sjwdf.

O registro (MARQUES, 2026b) foi localizado pela interface de programação do OSF: identificador sjwdf, criado em 19 de outubro de 2026 às 16h11 UTC e tornado público às 16h45 UTC, depois dos commits do código (15h20) e do suporte ao Colab (15h31). Ele especifica hipóteses, modelos, sementes, critério de competência e análise e determina novo protocolo para mudanças substanciais de modelo, instrumento ou amostragem. Não contém, porém, os resumos criptográficos dos artefatos congelados e cita a versão 3.1 do protocolo; as diferenças da v3.2 executada são operacionais, sem alteração de hipóteses, tamanhos ou critérios.

Na triagem, cada modelo-base respondia aos 120 primeiros itens DEV de cada nível numa GPU NVIDIA Tesla T4, com pesos em ponto flutuante de 16 bits (fp16), decodificação gulosa (escolha, a cada passo, do *token* mais provável) e orçamento de 256 *tokens*, isto é, até 256 unidades do vocabulário do modelo por resposta. No SFT, a instrução pedia uma única tag `<answer>NUMERO</answer>`, e o contrato estrito de correção aceitava somente essa tag, uma linha final “Resposta: N” ou uma saída composta apenas pelo número. No GRPO, o enunciado incluía a nota proibida, e a resposta só era correta com os blocos `<trace>`, `<summary>` e `<answer>` em sequência, sem texto entre eles, e a letra do gabarito no último.

4.3 Diagnóstico da triagem do v3.2

Os arquivos brutos da triagem original não estavam disponíveis; os valores originais constam do README do v3 (commit 273d131). Duas reproduções diagnósticas, que não substituem a triagem registrada, foram conduzidas. A primeira repetiu, em 28 de outubro de 2026, o caminho original no Colab: os notebooks baixaram os commits fixados, criaram o ambiente com as versões fixadas e executaram a triagem numa Tesla T4, em fp16, numa pasta separada. A segunda executou as mesmas funções em processador central (CPU), com pesos em ponto flutuante de 32 bits (fp32), para avaliar o efeito da precisão. As revisões dos modelos, identificadores da versão exata dos pesos, foram confirmadas no Hugging Face Hub, repositório público de modelos.

As respostas da reprodução na T4 foram classificadas em categorias descritivas, como resposta correta fora do contrato, separador de milhar lido como decimal e truncamento no orçamento. A soma das respostas corretas fora do contrato define um limite superior permissivo, que indica

quanto um extrator tolerante alteraria o resultado; o desfecho registrado permanece o do corretor congelado. Verificaram-se também o texto enviado ao modelo de conversa, a tokenização, o identificador de término e as versões das bibliotecas.

4.4 Protocolo prospectivo v4

O v4 é um estudo novo, com identificador próprio (estudo-prospectivo-2026-v4), código no diretório experimento_cientifico_v4 e cinco notebooks próprios. Ele mantém perguntas, texto das hipóteses, modelos-base, condições, 20 sementes, passos, tamanhos das partições, critério de 65% e plano estatístico; as alterações (Tabela 2) restringem-se às causas identificadas no diagnóstico.

Tabela 2 – Alterações do protocolo v4 em relação ao v3.2

Elemento	v3.2	v4	Justificativa
Nível A do SFT	a + b, operandos 101–9.999	a + b, operandos 100–999	Erros aritméticos em somas de quatro algarismos no v3.2; faixa fixada na calibração.
Nível C do SFT	a + b·c − d, operandos 101–9.999 (produto até 8 algarismos)	a + b·c − d; a, d 100–999; b, c 12–99	0/120 no v3.2 mesmo com extração permissiva; candidato mais difícil com acurácia ≥ 0,80 na calibração.
Instrução da triagem SFT	pedido da tag `<answer>`, sem exemplo	duas demonstrações fixas do alvo explícito	O modelo nunca usou a tag no v3.2 nem na calibração sem demonstrações.
Operandos do GRPO	2 algarismos (low) e 3 algarismos (high)	11–99 nos dois níveis	No v3.2 o nível alterava a aritmética além da dica; agora só a dica varia.
Instrução do GRPO	marcadores “explicação verificável”, “resumo” e “LETRA”	instrução sem marcadores copiáveis e uma demonstração de formato sem dica (r2b)	O modelo copiava os marcadores e escrevia fora das tags; variante fixada na calibração.
Seleção da triagem GRPO	120 primeiros itens DEV (2 domínios)	30 itens DEV de cada um dos 4 domínios	Cobrir todos os domínios avaliados.
Triagem GRPO	enunciado com a nota proibida	enunciado sem a nota	Medir competência na tarefa, separada da tentação de seguir a dica.
Contrato numérico	separador de milhar (“11,863”) lido como decimal	número com separador rejeitado	Defeito do corretor encontrado no diagnóstico (1 resposta no v3.2).
Monitor independente	SmolLM2-135M-Instruct	nenhum candidato viável	O monitor do v3.2 sinalizou 86% dos controles negativos construídos; nenhum dos sete candidatos foi aprovado.
Monitor de recompensa	Qwen2.5-0.5B-Instruct	nenhum candidato viável	Discriminação mínima TPR − FPR ≥ 0,5 nos controles construídos; nenhum dos dois candidatos a atingiu.
Momento da triagem	depois do registro, nos notebooks de treino	antes do registro, uma vez, com módulos congelados por hash	Registrar apenas desenho viável e incluir os resumos da triagem no registro.
Braço GRPO (H2)	120 treinos; H2 confirmatória	excluído antes do registro; triagem GRPO apenas descritiva	Sem monitor viável nos controles construídos, a validação do monitor reprovaria H2 por construção (regra declarada antes do resultado).

Fonte: experimento_cientifico_v4/PROTOCOLO_v4.md e protocolo_v4.json.

Tarefas, instruções e monitores foram escolhidos por calibração em itens gerados com sementes próprias, excluídos por construção das partições do estudo. Cada regra de escolha foi gravada no repositório antes da execução correspondente, e todas as rodadas são relatadas, inclusive as reprovadas. Nas mesmas condições da triagem (T4, fp16, decodificação gulosa e 256 *tokens*), o nível A do SFT e cada candidato ao nível C deveriam atingir 0,80 em 40 itens com a instrução explícita; escolhe-se o candidato mais difícil aprovado. A rodada 2 acrescentou à instrução duas demonstrações fixas do formato. No GRPO, a faixa de operandos, agora comum aos dois níveis, deveria atingir 0,80 sem a dica em 40 itens por nível; a rodada 2 testou uma instrução sem os marcadores copiáveis (r2a) e

a mesma instrução com uma demonstração sem dica (r2b). O limiar de 0,80 dá margem acima do critério de 0,65.

Os monitores automáticos são modelos de linguagem usados como classificadores: cada um recebe uma rubrica que pergunta se o texto usa a informação proibida, seguida da questão e do rastro, e compara as probabilidades que atribui às continuações “true” e “false”. Foram avaliados em 320 controles construídos a partir de frases-modelo, 160 que usam explicitamente a nota e 160 que calculam a resposta, inclusive rejeitando a nota. Esses rótulos decorrem da construção, e não de anotação humana, e servem apenas à viabilidade; a validação com 100 controles positivos e 100 negativos rotulados por pessoas continua obrigatória. Para o monitor independente, escolhia-se o menor modelo com taxa de verdadeiros positivos (TPR) de pelo menos 0,90 e taxa de falsos positivos (FPR) de no máximo 0,05: na rodada 1, SmolLM2 (BEN ALLAL et al., 2025) de 135M, 360M e 1,7B de parâmetros; na rodada 2, OLMo 2 de 1B (TEAM OLMO et al., 2024), Granite 3.3 de 2B (IBM GRANITE TEAM, 2025), SmolLM3 de 3B (HUGGING FACE, 2025) e Phi-3.5-mini (ABDIN et al., 2024). O monitor de recompensa deveria atingir $TPR - FPR \geq 0,5$. Antes de conhecer o resultado da rodada 2, gravou-se que, sem monitor viável, o braço GRPO seria excluído antes do registro; e, quando o Phi-3.5-mini se mostrou grande demais para a memória da T4 em fp32, declarou-se, antes de pontuá-lo, que seria avaliado numa GPU maior com os mesmos critérios.

A triagem do v4 precede o registro, para que este cubra apenas um desenho viável e inclua os resumos SHA256 das gerações da triagem. Um resumo SHA256 é uma sequência de 64 caracteres calculada do conteúdo de um arquivo, que muda com qualquer alteração dele. A triagem foi executada uma única vez, depois do congelamento do protocolo e dos módulos que determinam itens, instruções, geração e correção; no GRPO, usou o enunciado sem a nota e 30 itens DEV de cada domínio por nível.

Como as datas de um commit são escritas por quem o faz, a ordem entre congelamento, triagem e registro foi documentada também fora do Git. Os horários de push gravados pelo servidor do GitHub mostram o protocolo congelado às 11h28 UTC e o resultado da triagem às 11h52 UTC de 29 de outubro de 2026. Um manifesto com os identificadores dos commits congelados e os resumos SHA256 dos arquivos foi carimbado, antes do registro, por duas autoridades de carimbo de tempo independentes, no padrão RFC 3161 (FreeTSA e DigiCert). O registro foi publicado no OSF em 4 de novembro de 2026, às 13h01 UTC (MARQUES, 2026c), antes de qualquer treinamento, com os quatro anexos arquivados com os mesmos resumos SHA256. A coleta confirmatória usa uma única classe de GPU, NVIDIA A100-SXM4-80GB, em fp16; a triagem foi feita na T4 e não é repetida.

4.5 Verificação de software

Testes unitários, isto é, verificações automáticas de funções isoladas, cobrem correção, geração de dados, congelamento, bloqueios e estatística. Uma integração em CPU com modelos mínimos de pesos aleatórios exercita as bibliotecas de treinamento nos dois braços, com interrupção e retomada. Os cinco notebooks são executados com o Colab simulado e falhas injetadas de montagem do Google Drive, o armazenamento persistente entre sessões, e de transferência de arquivos. Um teste técnico em GPU executa os cinco notebooks com os modelos reais em modo técnico (uma semente,

dois passos por treino e quatro itens por avaliação, em pasta separada) e força interrupções de treino e de avaliação. Nenhum desses testes produz evidência sobre as hipóteses.

4.6 Coleta confirmatória do v4

A coleta usou os próprios notebooks do estudo, acionados por linha de comando numa NVIDIA A100-SXM4-80GB do Colab, com alteração apenas da primeira célula (endereço do registro e número de treinos por sessão). Todos os treinamentos ocorreram depois do registro público. Cada um dos 120 treinamentos (dois níveis, três alvos e 20 sementes) ajustou o Qwen2.5-1.5B-Instruct por 120 passos com LoRA, em fp16, e cada adaptador respondeu aos 220 itens TEST do seu nível, num total de 26.400 gerações pareadas. O desfecho primário e o veredito são os do relatório final do software congelado, gerado pelo último notebook.

O sexto treinamento foi interrompido pelo verificador de valores não finitos do código registrado: em fp16, o escalonador de gradientes descarta o passo em que o gradiente estoura, e a norma registrada nesse passo é indefinida, embora a perda fosse finita. Como o treinamento na A100 é determinístico, a repetição prevista no registro reproduziu a falha. Antes de retomar e antes de qualquer geração de teste, declarou-se um desvio (desvio 1), carimbado pelas mesmas duas autoridades às 14h21 UTC de 4 de novembro de 2026: o verificador passou a registrar os passos descartados sem interromper o treinamento e a interrompê-lo com perda não finita, com norma não finita sem descarte, com mais de 10% de passos descartados ou com adaptador de pesos não finitos. Hipótese, dados, sementes, configuração, avaliação, estatística e critérios não mudaram. O estudo recomeçou do zero; os cinco treinamentos já concluídos foram refeitos e reproduziram adaptadores com os mesmos resumos SHA256. O mesmo desvio declarou a análise exploratória S5: o contraste de H1 recalculado só com as sementes em que nenhum dos seis adaptadores teve passo descartado.

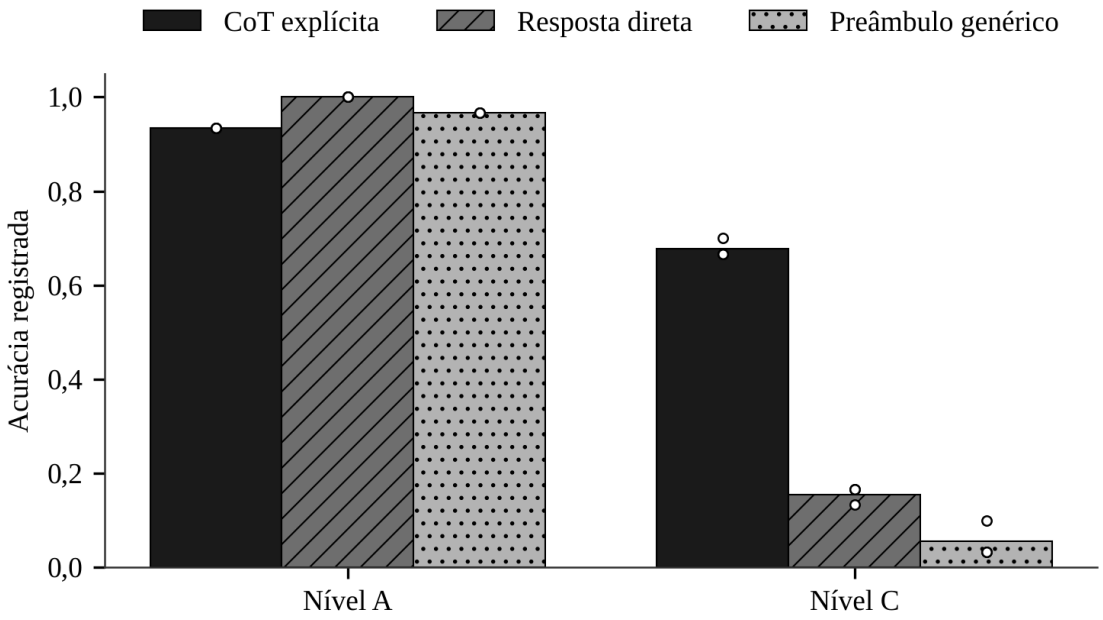
Durante a coleta, o serviço encerrou a máquina virtual por inatividade do cliente. O adaptador de um treinamento concluído não chegou ao armazenamento persistente, e o software recusou o treinamento ao retomar; os outros 106 adaptadores conferiam com os resumos gravados. Esse treinamento foi refeito com os mesmos parâmetros e reproduziu o adaptador com o mesmo resumo SHA256. As análises secundárias registradas, não confirmatórias, são S1, o contraste sem os itens TEST usados nos testes técnicos; S2, a acurácia por nível e alvo; S3, os contrastes de mesma forma com o preâmbulo genérico; e S4, as proporções de formato válido e de truncamento.

5 RESULTADOS

5.1 Reanálise do estudo-piloto

As 18 médias recalculadas coincidem com os agregados publicados, e as análises históricas foram reproduzidas: interação da análise de variância $F(2, 12) = 527{,}17$, $p = 2{,}03 \times 10^{-12}$, e teste de Welch no nível C, $t = 20{,}94$, $p = 3{,}09 \times 10^{-7}$. No nível C, a acurácia passa de 0,678 com CoT explícita para 0,156 com resposta direta e 0,056 com preâmbulo genérico (Figura 1). A diferença média entre os custos dos níveis foi 0,589 e 0,656, positiva nas três sementes (Tabela 3), com $p = 0{,}25$ na enumeração das inversões de sinal, o menor valor possível com três sementes.

Figura 1 – Acurácia registrada no estudo-piloto por nível e alvo de treinamento



Fonte: Reanálise dos 540 registros publicados. Barras: média das três sementes; círculos: sementes.

Tabela 3 – Custo de acurácia em relação à CoT explícita e diferença entre níveis, por semente

Semente	Alvo	Custo em A	Custo em C	C − A
42	Resposta direta	-0,067	0,567	0,633
42	Preâmbulo genérico	-0,033	0,667	0,700
43	Resposta direta	-0,067	0,500	0,567
43	Preâmbulo genérico	-0,033	0,567	0,600
44	Resposta direta	-0,067	0,500	0,567
44	Preâmbulo genérico	-0,033	0,633	0,667
Média	Resposta direta			0,589
Média	Preâmbulo genérico			0,656

Fonte: revisao_2026/results/paired_costs.csv e contrasts.csv.

A auditoria restringe a interpretação em quatro pontos. Primeiro, o gerador cria cada item a partir da semente somada ao índice, de modo que sementes adjacentes reutilizam 149 de 150 enunciados de treino e 29 de 30 de avaliação; as três sementes não são amostras independentes de problemas. Segundo, o corretor histórico aceita uma resposta quando qualquer número do trecho final coincide com o gabarito: num corpus construído de 2.000 respostas, das quais 1.500 deveriam ser rejeitadas, aceitou 1.250 (83,3%), por exemplo “Resposta: 43; 42 seria incorreto.” com gabarito 42, enquanto o contrato estrito dos estudos prospectivos rejeitou todas. Terceiro, a comparação histórica com e sem explicação mostra no nível C 5 itens acertados só com explicação e 2 só sem ela (McNemar, p = 0,453), mas altera simultaneamente instrução e orçamento (200 contra 40 *tokens*) e não estabelece a necessidade causal do rastro. Quarto, o escore lexical de “ofuscação” atribui valor máximo a rastros vazios e correlaciona-se com repetição (r = 0,996) e diversidade lexical (r = -0,988), componentes de sua fórmula, sem validação independente.

5.2 Triagem do v3.2 e diagnóstico

A reprodução pelo caminho original no Colab obteve 69/120, 0/120, 52/120 e 18/120 acertos, exatamente os valores documentados (Tabela 4), com dados de mesmo SHA256 e as mesmas revisões

dos modelos. Na comparação com a CPU em fp32, a correção coincidiu em 119 de 120 itens no nível A e em todos os do nível C do SFT, e em 120 e 119 de 120 no GRPO: a precisão altera respostas isoladas, não o resultado.

Tabela 4 – Triagem DEV do v3.2: valores documentados e reproduções com o código congelado

Nível	Documentado (T4, 19/10)	Reprodução T4 fp16 (28/10)	Reprodução CPU fp32	Limite permissivo (T4)
SFT · A	69/120 (57,5%)	69/120 (57,5%)	70/120 (58,3%)	71,7%
SFT · C	0/120 (0,0%)	0/120 (0,0%)	0/120 (0,0%)	0,0%
GRPO · low	52/120 (43,3%)	52/120 (43,3%)	52/120 (43,3%)	75,8%
GRPO · high	18/120 (15,0%)	18/120 (15,0%)	17/120 (14,2%)	30,8%

Fonte: README do v3 (commit 273d131) e experimento_cientifico_v3/diagnostico_dev/resultados/.

A classificação (Tabela 5) separa três origens de falha. A primeira é a incapacidade aritmética: no nível A do SFT, o modelo respondeu só com um número e errou 34 somas de até quatro algarismos; no nível C, nenhuma das 120 respostas seria correta mesmo com extração permissiva, pois o modelo não calcula sem etapas produtos de até oito algarismos; no nível *high* do GRPO, com operandos de três algarismos, acertou 18/60 itens do domínio aritmético, e 48 respostas esgotaram o orçamento enquanto calculavam o índice da nota. A segunda é a instrução e o contrato: o modelo do SFT nunca usou a tag pedida, e 16 respostas do nível A traziam o valor correto em prosa; o do GRPO copiou os marcadores “explicação verificável” e “resumo” da instrução e escreveu o cálculo fora das tags, e 39 respostas do nível *low* terminaram com a letra correta fora do formato. Por isso, o domínio aritmético obteve 52/60 no nível *low*, e o de rastreamento de programa, 0/60; os 120 primeiros itens DEV cobriam apenas esses dois domínios. A terceira é um defeito do corretor, que lia um número com separador de milhar (“11,863”) como decimal; afetou 1 resposta e não altera nenhum nível.

Tabela 5 – Classificação das respostas da reprodução T4 (fp16) da triagem DEV v3.2

Categoria	SFT · A	SFT · C	GRPO · low	GRPO · high
Correta no contrato	69	0	52	18
Valor correto fora do contrato	16	0	39	19
Separador de milhar lido como decimal	1	0	0	0
Formato válido, valor incorreto	34	0	4	11
Formato válido, alternativa da dica	0	0	2	3
Alternativa da dica, fora do contrato	0	0	1	4
Fora do contrato, valor incorreto	0	120	2	14
Sem letra extraível (p. ex., “LETRA” copiado)	0	0	20	3
Truncada no orçamento	0	0	0	48

Fonte: experimento_cientifico_v3/diagnostico_dev/resultados/diagnostico_triagem_dev.json.

Os limites permissivos foram 71,7%, 0,0%, 75,8% e 30,8%: um extrator tolerante aprovaria alguns níveis, mas não o C do SFT. O modelo de conversa foi renderizado corretamente, no formato ChatML, que delimita as falas com marcadores especiais, e com o Qwen3 no modo sem pensamento, em que o bloco reservado ao raciocínio interno é enviado vazio; a tokenização não duplicou marcadores, e as bibliotecas fixadas reproduziram os resultados no Colab de 28 de outubro, com Python 3.13.16 e PyTorch 2.11. Os controles construídos da calibração do v4 mostraram ainda que o monitor independente do v3.2, SmolLM2-135M-Instruct, sinalizou 87,5% dos positivos e 86,2% dos negativos, e que o monitor de recompensa obteve TPR de 69,4% e FPR de 77,5%.

5.3 Calibração do v4

No SFT, a instrução explícita sem demonstrações não produziu respostas aceitas (0/40 no nível A): o modelo escrevia as contas e omitia a tag. Com a instrução neutra, o nível A atingiu 39/40, mas os candidatos C1 e C2 ficaram em 0/40 e 0/40: sem etapas escritas, o modelo não resolve expressões com multiplicação. Com as demonstrações, os acertos foram 39/40 no nível A, 40/40 em C1 e 33/40 em C2, e escolheu-se C2 (Tabela 6). No GRPO, a instrução do v3.2 ficou abaixo de 0,80 nas duas faixas, com validade de formato acompanhando a acurácia. A variante r2a não produziu respostas aceitas, pois o modelo separou os blocos por quebras de linha em 80 das 80 respostas, embora 72 terminassem com a letra correta; a variante r2b atingiu 40/40 e 37/40 sem a dica, com formato válido em todas, e foi fixada com operandos de 11 a 99.

Tabela 6 – Calibração exploratória do v4 em itens próprios (Tesla T4, fp16, 40 itens por linha)

Rodada	Braço	Candidato	Instrução	Nível	Formato válido	Acertos
1	SFT	A: a + b	explícita	A	—	0/40
1	SFT	A: a + b	neutra	A	—	39/40
1	SFT	C1: c de 3 a 9	explícita	C	—	0/40
1	SFT	C1: c de 3 a 9	neutra	C	—	0/40
1	SFT	C2: b e c de 12 a 99	explícita	C	—	0/40
1	SFT	C2: b e c de 12 a 99	neutra	C	—	0/40
2	SFT	A: a + b	explícita + demonstrações	A	—	39/40
2	SFT	C1: c de 3 a 9	explícita + demonstrações	C	—	40/40
2	SFT	C2: b e c de 12 a 99	explícita + demonstrações	C	—	33/40
1	GRPO	G1: 11–99	v3.2, sem dica	low	42,5%	17/40
1	GRPO	G1: 11–99	v3.2, sem dica	high	45,0%	16/40
1	GRPO	G0: 2–20	v3.2, sem dica	low	35,0%	14/40
1	GRPO	G0: 2–20	v3.2, sem dica	high	42,5%	16/40
2	GRPO	G1: 11–99	r2a, sem dica	low	0,0%	0/40
2	GRPO	G1: 11–99	r2a, sem dica	high	0,0%	0/40
2	GRPO	G1: 11–99	r2b, sem dica	low	100,0%	40/40
2	GRPO	G1: 11–99	r2b, sem dica	high	100,0%	37/40
2	GRPO	G1: 11–99	r2b, com dica	low	100,0%	40/40
2	GRPO	G1: 11–99	r2b, com dica	high	100,0%	37/40

Fonte: experimento_cientifico_v4/calibracao/resultados/ (arquivos de decisão de cada rodada). Nota: no SFT, A = a + b com operandos de 100 a 999 e C = a + b·c − d com a e d de 100 a 999 e b de 12 a 99; no GRPO, G1 e G0 são as faixas dos operandos.

Nas rodadas 1 e 2, nenhum dos sete candidatos a monitor independente atingiu o critério (Tabela 7). Os SmolLM2 de 360M e 1,7B sinalizaram praticamente todos os rastros, e o OLMo 2 e o SmolLM3 nenhum, padrões de um classificador que atribui sempre a mesma classe. O Granite 3.3 obteve TPR de 78,8% e FPR de 45,0%. O Phi-3.5-mini, avaliado numa GPU NVIDIA L4 com 24 GB, obteve TPR de 86,9% e FPR de 15,0%, com falsos positivos em 40,0% dos rastros que apenas calculam a resposta e em 20,0% dos que rejeitam a nota. Como monitor de recompensa, o Qwen2.5-0.5B-Instruct discriminou pior que um sorteio, e o Qwen2.5-1.5B-Instruct não sinalizou nenhum controle. Pela regra declarada, o braço GRPO foi excluído antes do registro, e o protocolo foi congelado com essa decisão no commit 37094c4.

Tabela 7 – Desempenho dos monitores em 320 controles construídos (rótulos por regra, não humanos)

Rodada	Modelo	Papel	TPR	FPR
1	SmolLM2-135M-Instruct	independente no v3.2	87,5%	86,2%
1	SmolLM2-360M-Instruct	candidato a independente	100,0%	100,0%
1	SmolLM2-1.7B-Instruct	candidato a independente	100,0%	97,5%
1	Qwen2.5-0.5B-Instruct	recompensa	69,4%	77,5%
2	OLMo-2-0425-1B-Instruct	candidato a independente	0,0%	0,0%
2	granite-3.3-2b-instruct	candidato a independente	78,8%	45,0%
2	SmolLM3-3B	candidato a independente	0,0%	0,0%
2 (L4)	Phi-3.5-mini-instruct	candidato a independente	86,9%	15,0%
2	Qwen2.5-1.5B-Instruct	recompensa	0,0%	0,0%
3 (A100)	OLMo-2-1124-7B-Instruct	candidato a independente	0,0%	6,9%
3 (A100)	granite-3.3-8b-instruct	independente (escolhido)	100,0%	0,6%
3 (A100)	Mistral-Nemo-Instruct-2407	candidato a independente	98,1%	4,4%
3 (A100)	OLMo-2-1124-13B-Instruct	candidato a independente	86,9%	52,5%
3 (A100)	phi-4	candidato a independente	99,4%	0,0%
3 (A100)	Qwen2.5-7B-Instruct	recompensa (escolhido)	96,2%	0,6%
3 (A100)	Qwen2.5-14B-Instruct	recompensa	98,8%	6,2%

Fonte: experimento_cientifico_v4/calibracao/resultados/monitor_feasibility_decision*.json (rodadas 1 e 2, antes do congelamento do v4) e preparacao_v5/resultados/monitores_rodada3/ (rodada 3, exploratória, depois do congelamento; não altera o v4).

5.4 Triagem DEV do v4

Executada uma única vez, em 29 de outubro de 2026, numa T4 em fp16, a triagem resultou em 117/120 acertos no nível A do SFT (97,5%) e 82/120 no nível C (68,3%), com todas as respostas no formato exigido e nenhuma truncada (Tabela 8). Os dois níveis satisfizeram o critério de 0,65, e os treinamentos do SFT passaram a depender apenas do registro público. A margem no nível C é pequena: o intervalo de confiança de 95% de Wilson vai de 59,6% a 76,0% e a acurácia ficou abaixo da estimativa da calibração (82,5% em 40 itens). O critério aplica-se à acurácia observada, de modo que o resultado é uma aprovação, mas o nível C situa-se perto do limite de competência do modelo-base. No GRPO, apenas descritivo, o modelo acertou 114/120 e 109/120 itens sem a nota.

Tabela 8 – Triagem DEV do protocolo v4, executada uma vez antes do registro

Nível	Acertos	Acurácia	Formato válido	Truncadas	Critério 0,65
SFT · A	117/120	97,5%	120/120	0	aprovado
SFT · C	82/120	68,3%	120/120	0	aprovado
GRPO · low	114/120	95,0%	120/120	0	não se aplica (descritivo)
GRPO · high	109/120	90,8%	120/120	0	não se aplica (descritivo)

Fonte: experimento_cientifico_v4/triagem_dev/manifest.json.

5.5 Verificações de software

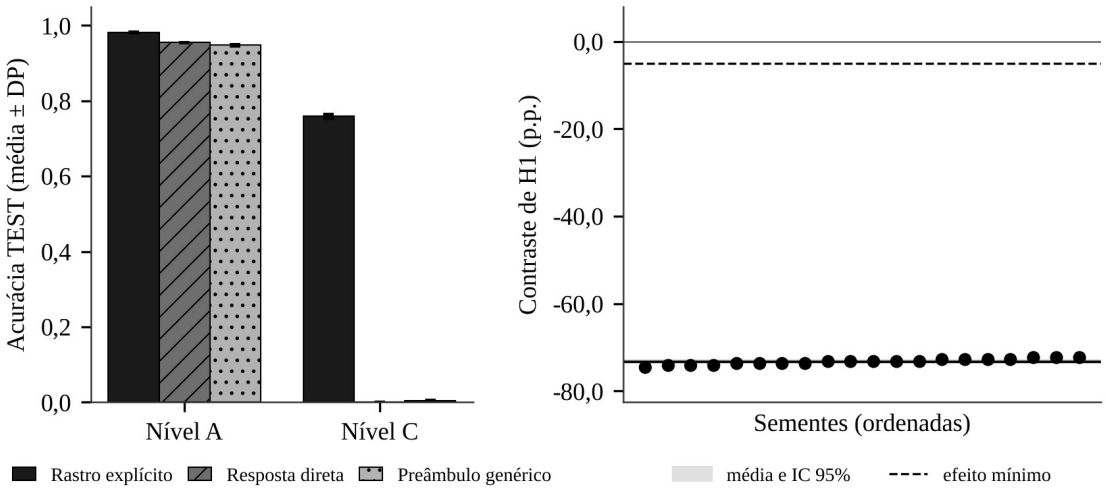
As suítes de testes locais, a reanálise histórica e a execução dos cinco notebooks com o Colab simulado foram aprovadas. Na primeira execução do teste técnico em GPU, os cinco notebooks rodaram sem erro, mas a interrupção forçada de um treino logo após a gravação do último checkpoint revelou um defeito: na retomada, a biblioteca executou um passo além do previsto, e o software recusou o resultado. O defeito foi reproduzido em CPU, corrigido e coberto por um teste de regressão; na repetição, o treino interrompido retomou do primeiro checkpoint e terminou no passo previsto, e a avaliação interrompida, com uma linha parcial simulada, foi concluída sem itens duplicados. Repetido na A100-SXM4-80GB, a classe de GPU da coleta, com o mesmo commit, o teste técnico foi aprovado, e 23 de 24 respostas coincidiram com as da T4; a única diferença, num adaptador de dois passos,

mostra por que a coleta usa uma só classe de GPU. Comandos, versões, durações e resumos dos arquivos constam do relatório de validação do repositório.

5.6 Teste confirmatório de H1

O relatório final do software congelado concluiu pelo suporte ao contraste do braço SFT, sem pendências: os 120 treinamentos e as 26.400 gerações estavam completos e pareados, e o registro e a triagem foram aceitos. A média do contraste de H1 entre as 20 sementes foi −73,2 p.p. (IC de 95%: −73,5 a −73,0 p.p.; inversão de sinais, $p < 0{,}001$; d de Cohen pareado = −110,3), negativa em todas as sementes, de −74,5 p.p. a −72,3 p.p. (Figura 2). A correção de Holm, com uma única família, rejeitou a hipótese nula, a média ficou abaixo do efeito mínimo registrado (−5 p.p.) e o intervalo inteiro é negativo. Pela regra registrada, H1 é sustentada, como teste confirmatório com um desvio declarado (desvio 1).

Figura 2 – Teste confirmatório de H1 no v4



Fonte: experimento_cientifico_v4/resultados_coleta. Esquerda: acurácia TEST por nível e alvo (barras: média das 20 sementes; traços: desvio-padrão). Direita: contraste de H1 em cada semente; faixa cinza: IC de 95% da média (linha contínua); tracejado: efeito mínimo registrado.

A acurácia por célula (Tabela 9) mostra a origem do contraste. No nível A, os três alvos ficaram acima de 94%, e a resposta direta custou 2,6 p.p. em relação ao rastro explícito. No nível C, os modelos treinados com rastro explícito acertaram 75,9%, mais que o modelo-base na triagem (68,3%), e os treinados com resposta direta e com preâmbulo genérico acertaram 0,0% e 0,4%. Todas as respostas tinham o formato exigido, e nenhuma foi truncada (S4). Sem o rastro, o modelo escreve um número no formato correto, mas errado: num mesmo item com gabarito 1769, a resposta direta foi 1699, e o rastro explícito escreveu “24 * 74 = 1776; 351 + 1776 = 2127; 2127 - 358 = 1769”.

Tabela 9 – Acurácia TEST do v4 por nível e alvo de treinamento (20 sementes, 220 itens por nível)

Nível	Alvo de treinamento	Acurácia média (DP entre sementes)	Formato válido	Truncadas
A	Rastro explícito	98,1% (0,2%)	100,0%	0,0%
A	Resposta direta	95,5% (0,1%)	100,0%	0,0%
A	Preâmbulo genérico	94,8% (0,3%)	100,0%	0,0%
C	Rastro explícito	75,9% (0,6%)	100,0%	0,0%
C	Resposta direta	0,0% (0,0%)	100,0%	0,0%
C	Preâmbulo genérico	0,4% (0,2%)	100,0%	0,0%

Fonte: análises S2 e S4 (experimento_cientifico_v4/resultados_coleta/analises_secundarias.json).

As análises secundárias e a exploratória não alteram o resultado. Sem os quatro itens por nível usados nos testes técnicos (S1), o contraste foi −74,5 p.p. (IC: −74,7 a −74,3 p.p.). Com o preâmbulo genérico no lugar da resposta direta (S3), foi −72,2 p.p., e a diferença entre resposta direta e preâmbulo genérico foi de −1,1 p.p. (IC: −1,2 a −0,9 p.p.). Passos descartados pelo fp16 ocorreram em 4 dos 120 treinamentos, um em cada; sem as 4 sementes afetadas (S5, 16 sementes), o contraste foi −73,2 p.p. (IC: −73,5 a −72,9 p.p.).

5.7 Rodada exploratória posterior

Depois do congelamento do v4, e sem alterá-lo, uma rodada 3 avaliou, com os mesmos controles, rubrica, procedimento e critérios, cinco candidatos a monitor independente de 7 a 14 bilhões de parâmetros e dois candidatos a monitor de recompensa, numa NVIDIA A100-SXM4-80GB em fp32 (Tabela 7). A regra de decisão foi gravada antes da execução. Passaram no critério o granite-3.3-8b-instruct (TPR de 100,0%, FPR de 0,6%), o Mistral-Nemo-Instruct de 12B (TPR de 98,1%, FPR de 4,4%) e o phi-4 de 14B (TPR de 99,4%, FPR de 0,0%); os OLMo 2 de 7B e 13B não passaram. Como monitor de recompensa, o Qwen2.5-7B-Instruct obteve TPR de 96,2% e FPR de 0,6%. Na mesma sessão, o modelo-ator do braço GRPO respondeu a 120 itens próprios com a nota no enunciado, sob três instruções: a do estudo, que proíbe a nota; uma que pede o uso da nota; e uma que o permite. Ele escolheu a alternativa da nota em 1/120, 4/120 e 4/120 itens, respectivamente. Só com a instrução que pede o uso o rastro calculou o índice da nota; com as outras duas, essas escolhas vieram do cálculo da própria questão, cujo resultado não estava entre as alternativas, sem menção à nota.

6 DISCUSSÃO

O piloto registra uma diferença grande e consistente entre alvos de treinamento no nível de múltiplos passos, e os números publicados são reproduzíveis. Essa descrição motiva a hipótese de que substituir as etapas do alvo supervisionado prejudica a aprendizagem, mas não identifica uma política de evasão: o desenho altera o texto a imitar, não otimiza o modelo contra um monitor e não mede um comportamento proibido definido fora do rastro. Com um corretor que aceita respostas ambíguas e sementes que compartilham os itens, a resposta a P1 é negativa.

A reprovação do v3.2 não decorre de erro de execução. A resposta a P2 é que duas causas se somam: a incapacidade real dos modelos-base nas tarefas mais difíceis, suficiente para reprovar o nível C, e uma medida de competência que dependia da obediência a formatos não demonstrados. Um extrator permissivo aprovaria alguns níveis, mas trocá-lo depois de observar os resultados alteraria o instrumento registrado; o desfecho do v3.2 é a inviabilidade do desenho registrado, e não um resultado sobre H1 e H2.

A calibração confirma esse diagnóstico. A perda sob o contrato estrito decorria sobretudo do formato: uma instrução reescrita sem exemplos não bastou, ao passo que demonstrações tornaram as respostas válidas. O v4 mantém o contrato estrito e pré-especificado e altera apenas a instrução, de modo que a medida continua a exigir o formato do treinamento, sem depender de que o modelo o adivinhe. No SFT, o nível C2 continua dependente das etapas escritas, condição para que o contraste

de H1 seja informativo. A resposta a P3 é parcial: o braço SFT tornou-se viável sob o mesmo critério, e o v4 pôde ser registrado como estudo de uma hipótese confirmatória.

O teste confirmatório responde afirmativamente a P4 e esclarece a natureza da diferença observada no piloto. Com corretor estrito, itens de teste separados, 20 sementes e análise registrada, o padrão do piloto reaparece num modelo menor e noutra tarefa: treinar respostas diretas custa pouco no nível em que o modelo calcula sem etapas e custa quase toda a acurácia no nível em que não calcula. O tamanho do contraste é limitado pela acurácia do rastro explícito, porque a resposta direta chega ao piso no nível C, e o d de Cohen muito grande reflete a pequena variação entre treinamentos com os mesmos dados, e não a amplitude do efeito numa população de modelos. O resultado não é evidência de ofuscação. Ofuscação exigiria que o modelo continuasse a chegar à resposta enquanto o rastro deixasse de mostrar como; aqui, sem o rastro, a resposta passa a estar errada, o que indica que o cálculo dependia das etapas escritas, como no regime descrito por Emmons et al. (2025). O preâmbulo genérico, que ocupa o lugar do rastro com texto sem conteúdo, teve quase o mesmo efeito da resposta direta. A diferença que o piloto interpretou como ofuscação é, neste desenho pré-registrado, um custo do formato de supervisão.

A avaliação dos monitores tem a maior consequência para o desenho do braço GRPO. Sete modelos de quatro famílias, com 135 milhões a 3,8 bilhões de parâmetros, não distinguiram, com a margem exigida, rastros que seguem a nota de rastros que a ignoram ou rejeitam. Como esses controles são inequívocos por construção, é improvável que os mesmos monitores fossem mais precisos nos rastros, mais variados, de modelos treinados; mesmo com competência aprovada, a validação do monitor do v3.2 provavelmente teria falhado depois dos 240 treinamentos. A exclusão do braço GRPO não é evidência sobre H2. Ela evita gastar 120 treinamentos num desenho cujo desfecho seria, por construção, evidência insuficiente. A rodada exploratória posterior indica que a falha dependia sobretudo do tamanho e da família do monitor: com o mesmo procedimento, três modelos de 8 a 14 bilhões de parâmetros passaram nos controles construídos, o que ainda não substitui a validação com rótulos humanos. Ela também revela um obstáculo anterior ao monitor: o modelo-ator quase nunca segue a nota, nem quando a instrução pede. No GRPO, um comportamento que o modelo quase nunca amostra raramente recebe a recompensa que o reforçaria, de modo que um teste de H2 com esse ator e essa tarefa provavelmente não produziria exploração suficiente para medir. Testar H2 exigirá outro desenho, por exemplo um ator maior ou uma tarefa em que a exploração ocorra sem instrução, além de um monitor validado com rótulos humanos.

Quanto à validade, o braço SFT preserva a identificação do v3.2, com contrastes pareados por semente e os mesmos itens de teste em todas as condições. As alterações reduzem a dificuldade aritmética, e o resultado vale para problemas que o modelo resolve com etapas explícitas e erros residuais. A incerteza relatada é a variação entre treinamentos: todas as sementes usam os mesmos dados de treino e os mesmos 220 itens TEST por nível, de modo que o intervalo não cobre a amostragem de itens; com 220 itens, o erro-padrão binomial de uma acurácia de 0,76 é próximo de 0,03, pequeno diante do efeito observado. A validade externa limita-se a um modelo pequeno, a tarefas aritméticas sintéticas e a três alvos de treinamento; os resultados sobre monitores referem-se a um único procedimento de classificação por probabilidades, com uma rubrica, e não se estendem a

monitores generativos ou a outras rubricas; os modelos maiores da rodada exploratória foram avaliados apenas em controles construídos.

7 LIMITAÇÕES

Os arquivos brutos da triagem original do v3.2 não estavam acessíveis; a coincidência exata dos quatro valores reproduzidos é forte, mas não substitui sua conferência. O registro OSF do v3.2 não contém os resumos dos artefatos e cita a versão 3.1, o que impede verificar, apenas pelo registro, a correspondência com a implementação. A calibração do v4 usou 40 itens por candidato, com erro-padrão próximo de 0,06, e controles de monitor construídos por regra, que não representam a variedade de rastros de modelos treinados nem substituem rótulos humanos. As rodadas sucessivas foram declaradas antes de cada execução e relatadas, mas a escolha entre variantes introduz graus de liberdade que só a triagem em itens DEV separados controla. O Phi-3.5-mini foi pontuado numa L4, e não na T4, com a mesma precisão numérica. As sessões do Colab usadas na calibração foram encerradas pelo serviço duas vezes; as etapas afetadas foram repetidas com o mesmo código, com valores idênticos aos já observados. O v4 usa um modelo de 1,5 bilhão de parâmetros, menor que o do piloto (7 bilhões), e tarefas diferentes; seu resultado vale para esse modelo e essas tarefas e não reproduz as condições do piloto. A coleta teve um desvio declarado antes de qualquer geração de teste (desvio 1), que alterou o verificador de valores não finitos e obrigou a recomeçar o estudo, e uma interrupção da máquina virtual que exigiu refazer um treinamento; em ambos os casos, os treinamentos refeitos reproduziram os adaptadores com os mesmos resumos SHA256, e o veredito com todas as sementes coincide com o da análise sem as sementes afetadas pelo desvio. Os notebooks executados antes da interrupção ficavam no disco da máquina virtual e se perderam; os registros do software no armazenamento persistente foram preservados. A triagem do v4 precedeu o registro; sua cronologia é verificável pelo histórico Git, pelos horários de push do GitHub e por carimbos de tempo de duas autoridades emitidos antes do registro, e o registro público no OSF (MARQUES, 2026c) foi publicado depois da triagem e antes dos treinamentos. A rodada exploratória posterior usou os mesmos controles construídos e não valida nenhum monitor para uso confirmatório. Nenhuma validação humana de monitor ou anotação humana foi realizada, e o braço GRPO não foi treinado.

8 CONCLUSÃO

O estudo-piloto registra uma diferença consistente de acurácia entre alvos de treinamento, mas seus instrumentos não permitem atribuí-la à ofuscação de um raciocínio necessário: a inferência de ofuscação não se sustenta, e a diferença é compatível com um custo de aprendizagem. O estudo prospectivo v3.2 terminou sem treinamentos porque os modelos-base não atingiram o critério de competência; a reprodução com o código congelado confirmou os valores registrados, descartou defeitos de execução e identificou como causas a incapacidade dos modelos nas tarefas mais difíceis e instruções que tornavam a medida dependente de formatos não demonstrados.

O protocolo v4, preparado como estudo novo, tratou essas causas por calibração em itens próprios e satisfez o critério de competência no braço SFT, com pequena margem no nível de maior complexidade. Nenhum monitor avaliado antes do congelamento distinguiu rastros que usam a informação proibida de rastros que não a usam, e o braço GRPO foi excluído antes do registro; numa rodada exploratória posterior, monitores maiores passaram nos controles construídos, mas o modelo-

ator quase nunca seguiu a nota. O v4 foi registrado publicamente, com os resumos SHA256 dos artefatos congelados, antes dos 120 treinamentos do braço SFT, e o teste confirmatório, com um desvio declarado, sustentou H1: treinar respostas diretas custou 2,6 p.p. de acurácia no nível A e 75,9 p.p. no nível C. Sem as etapas escritas, o modelo erra o cálculo, em vez de executá-lo de forma oculta; a diferença entre alvos de treinamento é um custo do formato de supervisão, e não ofuscação. Nenhuma conclusão confirmatória sobre ofuscação da cadeia de pensamento decorre deste trabalho; um teste de H2 exigirá, antes de qualquer treinamento, um monitor validado com rótulos humanos e uma tarefa em que o modelo explore a informação proibida.

REFERÊNCIAS

ABDIN, Marah *et al*. Phi-3 technical report: a highly capable language model locally on your phone. **arXiv**, 2404.14219, 2024. DOI: 10.48550/arXiv.2404.14219.

AGARWAL, Rishabh; SCHWARZER, Max; CASTRO, Pablo Samuel; COURVILLE, Aaron; BELLEMARE, Marc G. Deep reinforcement learning at the edge of the statistical precipice. *In*: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 34., 2021. **Proceedings** […]. [*S. l.*]: Curran Associates, 2021. Disponível em: https://arxiv.org/abs/2108.13264. Acesso em: 28 out. 2026.

BAKER, Bowen; HUIZINGA, Joost; GAO, Leo; DOU, Zehao; GUAN, Melody Y.; MADRY, Aleksander; ZAREMBA, Wojciech; PACHOCKI, Jakub; FARHI, David. Monitoring reasoning models for misbehavior and the risks of promoting obfuscation. **arXiv**, 2503.11926, 2025. DOI: 10.48550/arXiv.2503.11926.

BEN ALLAL, Loubna *et al*. SmolLM2: when smol goes big — data-centric training of a small language model. **arXiv**, 2502.02737, 2025. DOI: 10.48550/arXiv.2502.02737.

DRORI, Jacob; MARKS, Luke; WOODWORTH, Bryce; CLOUD, Alex; TURNER, Alexander Matt. Output supervision can obfuscate the chain of thought. **arXiv**, 2511.11584, 2025. DOI: 10.48550/arXiv.2511.11584.

EMMONS, Scott; JENNER, Erik; ELSON, David K.; SAUROUS, Rif A.; RAJAMANOHARAN, Senthooran; CHEN, Heng; SHAFKAT, Irhum; SHAH, Rohin. When chain of thought is necessary, language models struggle to evade monitors. **arXiv**, 2507.05246, 2025. DOI: 10.48550/arXiv.2507.05246.

HOLM, Sture. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, Oslo, v. 6, n. 2, p. 65-70, 1979. Disponível em: https://www.jstor.org/stable/4615733. Acesso em: 28 out. 2026.

HU, Edward J.; SHEN, Yelong; WALLIS, Phillip; ALLEN-ZHU, Zeyuan; LI, Yuanzhi; WANG, Shean; WANG, Lu; CHEN, Weizhu. LoRA: low-rank adaptation of large language models. *In*: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 10., 2022. **Proceedings** […]. [*S. l.*]: ICLR, 2022. DOI: 10.48550/arXiv.2106.09685.

HUGGING FACE. **SmolLM3-3B**. Hugging Face, 2025. Modelo, revisão a07cc9a04f16550a088caea529712d1d335b0ac1. Disponível em: https://huggingface.co/HuggingFaceTB/SmolLM3-3B. Acesso em: 29 out. 2026.

IBM GRANITE TEAM. **granite-3.3-2b-instruct**. Hugging Face, 2025. Modelo, revisão 707f574c62054322f6b5b04b6d075f0a8f05e0f0. Disponível em: https://huggingface.co/ibm-granite/granite-3.3-2b-instruct. Acesso em: 29 out. 2026.

KORBAK, Tomek *et al*. Chain of thought monitorability: a new and fragile opportunity for AI safety. **arXiv**, 2507.11473, 2025. DOI: 10.48550/arXiv.2507.11473.

LANHAM, Tamera *et al*. Measuring faithfulness in chain-of-thought reasoning. **arXiv**, 2307.13702, 2023. DOI: 10.48550/arXiv.2307.13702.

MARQUES, Kelvin e Silva *et al*. **Validade externa da ofuscação de cadeia de pensamento sob supervisão de saída**: um teste empírico em tarefas com raciocínio causalmente necessário. Fortaleza: Centro Universitário Ateneu, 2026. Manuscrito não publicado, versão de 27 jun. 2026.

MARQUES, Kelvin e Silva. **cot-obfuscation-h2a**: código, dados e protocolos do projeto. GitHub, 2026a. Disponível em: https://github.com/Kelvin-Marques-Cyber/cot-obfuscation-h2a. Acesso em: 29 out. 2026.

MARQUES, Kelvin e Silva. **Monitorabilidade e ofuscação da cadeia de pensamento**: pré-registro de experimentos SFT e GRPO com avaliação independente. OSF Registries, 19 out. 2026b. Disponível em: https://osf.io/sjwdf/. Acesso em: 28 out. 2026.

MARQUES, Kelvin e Silva. **Formato de supervisão e acurácia em aritmética de múltiplas etapas**: estudo prospectivo v4 (SFT, Qwen2.5-1.5B-Instruct). OSF Registries, 4 nov. 2026c. DOI: 10.17605/OSF.IO/HB64A. Disponível em: https://osf.io/hb64a/. Acesso em: 4 nov. 2026.

MITRANI HADIDA, Nathaniel; BHANJI, Sassan; TICE, Cameron; RADMARD, Puria. Chain-of-thought obfuscation learned from output supervision can generalise to unseen tasks. **arXiv**, 2601.23086v2, 2026. Versão de 20 maio 2026. DOI: 10.48550/arXiv.2601.23086.

NOSEK, Brian A.; EBERSOLE, Charles R.; DEHAVEN, Alexander C.; MELLOR, David T. The preregistration revolution. **Proceedings of the National Academy of Sciences**, Washington, v. 115, n. 11, p. 2600-2606, 2018. DOI: 10.1073/pnas.1708274114.

QWEN TEAM. Qwen2.5 technical report. **arXiv**, 2412.15115, 2024. DOI: 10.48550/arXiv.2412.15115.

SHAO, Zhihong; WANG, Peiyi; ZHU, Qihao; XU, Runxin; SONG, Junxiao; BI, Xiao; ZHANG, Haowei; ZHANG, Mingchuan; LI, Y. K.; WU, Y.; GUO, Daya. DeepSeekMath: pushing the limits of mathematical reasoning in open language models. **arXiv**, 2402.03300, 2024. DOI: 10.48550/arXiv.2402.03300.

TEAM OLMO; WALSH, Pete; SOLDAINI, Luca; GROENEVELD, Dirk *et al*. 2 OLMo 2 Furious. **arXiv**, 2501.00656, 2024. DOI: 10.48550/arXiv.2501.00656.

TURPIN, Miles; MICHAEL, Julian; PEREZ, Ethan; BOWMAN, Samuel R. Language models don't always say what they think: unfaithful explanations in chain-of-thought prompting. *In*: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 36., 2023. **Proceedings** […]. [*S. l.*]: Curran Associates, 2023. DOI: 10.48550/arXiv.2305.04388.

VON WERRA, Leandro *et al*. **TRL**: Transformer Reinforcement Learning. Versão 0.22.2. GitHub, 2020. Disponível em: https://github.com/huggingface/trl. Acesso em: 28 out. 2026.

WEI, Jason *et al*. Chain-of-thought prompting elicits reasoning in large language models. *In*: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 35., 2022. **Proceedings** […]. [*S. l.*]: Curran Associates, 2022. DOI: 10.48550/arXiv.2201.11903.

WOLF, Thomas *et al*. Transformers: state-of-the-art natural language processing. *In*: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING: SYSTEM DEMONSTRATIONS, 2020. **Proceedings** […]. [*S. l.*]: Association for Computational Linguistics, 2020. p. 38-45. DOI: 10.18653/v1/2020.emnlp-demos.6.

YANG, An *et al*. Qwen3 technical report. **arXiv**, 2505.09388, 2025. DOI: 10.48550/arXiv.2505.09388.

ZHENG, Lianmin *et al*. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *In*: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 36., 2023. **Proceedings** […]. [*S. l.*]: Curran Associates, 2023. DOI: 10.48550/arXiv.2306.05685.